

HCTD: 基于 CNN-Transformer 混合架构的 高精度无人机影像目标检测器

A CNN-transformer hybrid for precise object detection in UAV aerial imagery

汇报人: 郭帅 | 导师: 周锦程

研究背景与动机

无人机航空影像目标检测在安防监控、地理测绘等领域应用广泛，但面临诸多技术挑战，现有方法存在明显局限性。


⚠️ 核心检测挑战

- 🔍 小目标像素稀缺
目标占据像素少，易受下采样导致特征丢失和背景噪声干扰。
- ⚠️ 复杂背景干扰
目标与背景相似度高，背景噪声大，难以有效区分。
- 📏 多尺度变异
同一帧内目标大小差异巨大（如建筑物与行人），需同时处理不同尺度目标。
- 🔄 任意方向与遮挡
目标旋转角度任意，易被遮挡，视觉形状变化大。
- 🖼️ 类内差异与类间相似
目标类别区分度低，但同一类目标因环境变化差异大。

✖️ 现有方法局限性

- 🌐 全局语义建模困难
难以有效捕捉全局语义信息，影响对复杂场景的理解。
- 📦 特征下采样信息丢失
特征金字塔构建过程中，小目标特征易在下采样时丢失。
- ↔️ 跨层特征交互冗余
跨层特征交互中存在冗余和不一致，影响检测精度。
- ⌚ 计算成本与实时性
计算成本高，难以在资源受限的无人机平台上实现实时应用。

HCTD 整体架构概览



端到端混合检测范式，
实现了从特征提取到最终预测的全流程优化，
旨在解决复杂场景下的检测精度与速度瓶颈。

模型整体架构组成

- **骨干网络 (Backbone):**提取输入图像的多尺度基础特征，为后续加工提供支撑。
- **混合编码器 (Hybrid Encoder):**核心组件，负责特征的提纯、深层融合与全局交互。
- **解码器 (Decoder):**通过迭代优化对象查询，精准生成最终的目标类别标签与边界框。

混合编码器三大核心创新模块

- **特征过滤模块 (FFM):**自适应增强显著特征，有效抑制背景噪声干扰。
- **卷积加性自注意力 (CASFI):**兼顾计算效率与感受野，高效实现全局上下文建模。
- **全局上下文流特征金字塔 (GC²FPN):**优化跨分辨率特征交互，显著改善语义一致性。

创新点一：特征过滤模块 (FFM)




图1. 特征过滤模块 (FFM) 架构示意图

展示了CSA模块内部的特征交互与注意力生成过程

模块目的

增强目标区域的感知显著性，有效抑制背景噪声干扰，减少特征通道间的信息冗余，为后续任务提供高质量的特征表达。

核心原理：上下文选择注意力 (CSA) 模块

01 双全局池化

结合平均池化（语义）与最大池化（显著），全方位捕获全局特征信息。


02 双路卷积融合

条形卷积捕获方向特征，标准卷积捕获全向信息，低成本获取丰富上下文。

03 动态权重生成

生成像素级注意力权重图，对特征加权以突出目标并抑制背景噪声。

创新点二：卷积加性自注意力机制 (CASFI)




研究目的

以高效的方式替代计算昂贵的标准自注意力机制，在大幅降低计算复杂度的同时，实现特征间高效、全局的信息交互。

核心原理 (Token Mixer)

- 替代点积：将传统相似度计算 $Q \times K^T$ 替换为加性融合 $\Phi(Q) + \Phi(K)$ ，降低计算量。
- 双重注意力：算子 $\Phi(\cdot)$ 融合了空间与通道注意力，有效捕获多维特征依赖。
- 隐式编码：利用卷积归纳偏置隐式建模空间关系，省略显式位置编码，进一步提升效率。

创新点三：全局上下文流特征金字塔 (GC2FPN)



研究目的

解决传统特征金字塔网络(FPN)中不同层级特征融合时的语义不一致问题，有效增强网络对多尺度、尤其是小目标物体的特征提取与表达能力。



模块一：全局上下文信息融合 (GCIF)

摒弃传统的简单相加融合方式，引入CSA模块对底层的强定位特征进行“语义过滤”，仅保留与高层语义相关的信息；再与经过上采样的高层强语义特征进行融合，实现重要信息的精准、选择性传递。




模块二：移位特征增强 (SFE)

在特征融合后，集成Shift-Conv (移位卷积)机制，通过灵活的空间采样策略，在不增加计算成本的前提下，有效扩大感受野并增强对局部与全局空间特征的感知能力。

与主流检测器的性能对比 (VisDrone2019)


模型	主干网络	参数量 (M)	FPS (推理速度)	AP50 (%)	APS (小目标)
YOLOv8-M	-	25.8	85	34.7	9.8
RT-DETR-R18	ResNet-18	20.1	136	36.5	11.6
RT-DETR-R50	ResNet-50	42.3	98	38.5	12.7
HCTD-R18 (Ours)	ResNet-18	23.6	120	38.2	13.9
HCTD-R50 (Ours)	ResNet-50	45.4	94	43.7	14.7

TIDE 细粒度误差分析



- ✓ 分类错误 最低: Cls Error 仅**13.91%**，特征提取与类别判别能力强，识别准确。
- ✓ 定位精度极高: Loc Error 低至 3.91%，边界框回归精准。
- ✓ 背景抗干扰强: Bkgd False Positive 仅 1.91%。模型对复杂背景具有强抗干扰能力，极少误判。
- ✓ 漏检率显著降低: Missed Error 仅**12.09%**，优于绝大多数对比模型，目标召回率更高。

消融实验与性能增益验证



FFM 模块

单独引入使 AP50 提升 4.42%。有效抑制特征冗余，增强显著区域感知。

GC2FPN 模块

使 APS 提升至 13.9%。证实跨层语义融合对小目标检测的决定性作用。

CASFI 优化

将推理速度从 98 提升至 112 FPS。大幅优化计算成本，确保实时性能。

结论与未来研究展望

✓ 研究结论

- 🤖 端到端混合检测器
HCTD是专为无人机影像设计的CNN-Transformer混合检测器，通过FFM、CASFI和GC2FPN三大模块有效处理复杂场景挑战。
- 🏆 超越现有SOTA方法
在VisDrone2019数据集上，HCTD在检测精度（AP50: 43.7%）和实时性能（94 FPS）方面均表现优异。
- 📈 细粒度错误分析优势
TIDE分析显示HCTD在分类错误（13.91%）、定位错误（3.91%）和漏检率（12.09%）方面具有显著优势。
- ⚙️ 模块有效性验证
消融研究证实了FFM、CASFI和GC2FPN模块在提升小目标检测性能和全局上下文建模方面的有效性。

🔮 未来研究展望

- 🔍 极端小目标与密集目标处理
借鉴两阶段检测框架思想，改进对极端小目标和密集重叠目标的检测能力。
- 🕒 模型轻量化与部署优化
避免网络结构过度复杂，确保模型能在资源受限的无人机平台上高效部署。
- 📡 多模态信息融合
探索与红外热成像等传感器数据的融合，提升极端条件下的检测鲁棒性。
- 🧠 智能注意力机制
引入空间注意力或可变形卷积，使模型更智能地聚焦高概率区域。
- ⚙️ 自动化参数优化
引入自动化寻优方法优化参数空间，提升模型综合性能指标。